

# Trabalho Final de SQL para Ciência de Dados - CI245

Análise de Dados com SQL sobre Ocupações dos Leitos de COVID nos Anos de 2020, 2021 e 2022.

## Table of contents

0.1	Introdução . . . . .	2
0.2	Conexão com Banco de Dados . . . . .	2
0.3	Limpeza de Dados . . . . .	2
0.3.1	Criação de views . . . . .	3
0.3.2	Remoção de registros (notificações) com status excluídos . . . . .	3
0.3.3	Remoção (filtro) de registros que continham valores decimais . . . . .	4
0.3.4	Validação de colunas de acordo com informações do dicionário de dados . . . . .	4
0.3.5	Remoção de notificações duplicadas . . . . .	7
0.3.6	Criação de colunas calculadas . . . . .	8
0.3.7	Criação de série temporal . . . . .	9
0.3.8	Execução de ‘Last Observation Carried Forward (LOCF)’ para tratamento de valores nulos em séries temporais. . . . .	10
0.3.9	Criação de <b>materialized view</b> como tabela final para facilitar uso durante consulta dos dados tratados. . . . .	11
0.4	Análise de Dados . . . . .	12
0.4.1	Views e/ou CTE’s . . . . .	12
0.4.2	Subconsultas . . . . .	12
0.4.3	Deteção de Anomalias: registros com picos isolados . . . . .	12
0.4.4	Deteção de Anomalias: registros com picos isolados . . . . .	13
0.4.5	Análise de Texto: origem dos dados . . . . .	15
0.4.6	Evolução das altas e óbitos ao longo do tempo . . . . .	16
0.4.7	Evolução da ocupados COVID vs ocupados hospitalar . . . . .	17
0.4.8	Ocupação máxima de leitos por hospital . . . . .	17
0.5	Observações Finais . . . . .	18

## 0.1 Introdução

Este relatório tem como objetivo realizar a análise de dados sobre a ocupação dos leitos hospitalares destinados ao tratamento de COVID-19 nos anos de 2020, 2021 e 2022, utilizando SQL como ferramenta principal. A análise foi realizada com base em um banco de dados com informações obtidas através de arquivos .csv e estão disponíveis em: <https://opendatasus.saude.gov.br/dataset/registro-de-ocupacao-hospitalar-covid-19>. Tais dizem respeito a ocupação dos leitos, registros de óbitos e outras métricas relevantes.

As principais análises realizadas foram: - Detecção de anomalias: registros com picos isolados; - Análise de Texto: origem dos dados; - Evolução das altas e óbitos ao longo do tempo.

Para tanto foram utilizadas técnicas de **SQL** para manipulação e análise dos dados, com foco na extração de informações relevantes e na identificação de padrões e anomalias.

## 0.2 Conexão com Banco de Dados

```
library(DBI)
library(RPostgres)

# Criando conexão (exemplo PostgreSQL)
con <- dbConnect(
  RPostgres::Postgres(),
  dbname = "ocupacao",
  host = "localhost",
  port = 5432,
  user = "postgres",
  password = senha)
```

## 0.3 Limpeza de Dados

Antes de fazermos qualquer análise estatística, precisamos garantir que os dados estão modelados de tal forma que sejam íntegros e de qualidade. Não à toa, já é clichê dizer que boa parte do trabalho de qualquer analista ou cientista de dados é a limpeza dos dados, afinal a máxima “garbage in, garbage out” é uma realidade.

Essa base de dados, por serem preenchidas por humanos em alguns casos, possui alguns problemas que, a **priori**, dificultaram o nosso entendimento sobre as informações que os dados nos trazem. Lendo o dicionário de dados com acuracidade, conseguimos identificar quais padrões poderiam nos guiar na validação destes dados.

Assim, para o tratamento de dados, foram realizadas algumas etapas. Para cada uma, views foram criadas para ajudar na organização do código. 1 - Remoção (filtro) de registros (notificações) com status excluídos 2 - Remoção (filtro) de registros que continham valores decimais. 3 - Validação de colunas de acordo com informações do dicionário de dados. 4 - Remoção de notificações duplicadas 5 - Criação de colunas calculadas 6 - Criação de série temporal 7 - Execução de ‘Last Observation Carried Forward (LOCF)’ para tratamento de valores nulos em séries temporais. 8 - Criação de **materialized view** como tabela final para facilitar uso durante consulta dos dados tratados.

### 0.3.1 Criação de views

Antes de executarmos o **script** que cria a **materialized view** final, garantimos que já não existe no banco de dados outros objetos com o mesmo nome. Para isso, executamos o comando “**DROP VIEW IF EXISTS nome\_da\_view**”; para cada view que vamos criar.

```
DROP MATERIALIZED VIEW IF EXISTS registro_ocupacao_final;
```

```
DROP VIEW IF EXISTS registro_ocupacao_07_locf;
```

```
DROP VIEW IF EXISTS registro_ocupacao_06_serie_temporal;
```

```
DROP VIEW IF EXISTS registro_ocupacao_05_colunas_calculadas_filtradas;
```

```
DROP VIEW IF EXISTS registro_ocupacao_04_sem_duplicatas;
```

```
DROP VIEW IF EXISTS registro_ocupacao_03_dados_limpos;
```

```
DROP VIEW IF EXISTS registro_ocupacao_02_sem_decimais;
```

```
DROP VIEW IF EXISTS registro_ocupacao_01_nao_excluido;
```

### 0.3.2 Remoção de registros (notificações) com status excluídos

Observamos que alguns registros continham status de exclusão com valores lógicos **true**, o que não faz sentido para a análise. Assim, criamos uma view que filtra esses registros para manter apenas aqueles com status não excluídos.

```
-- 01: Remove registros com status excluidos
CREATE OR REPLACE VIEW registro_ocupacao_01_nao_excluido AS
  SELECT ro.*
  FROM registro_ocupacao ro
  LEFT JOIN status_envio se
    ON ro.id_status = se.id_status
  WHERE excluido = false;
```

### 0.3.3 Remoção (filtro) de registros que continham valores decimais

Alguns valores de ocupação e saída continham valores decimais (valores relativos pois não passavam de 100), o que não faz sentido para a análise, pois esses valores deveriam ser inteiros. Assim, criamos uma view que filtra esses registros para manter apenas aqueles com valores inteiros.

```
-- 02: Remove valores decimais
CREATE OR REPLACE VIEW registro_ocupacao_02_sem_decimais AS
  SELECT * FROM registro_ocupacao_01_nao_excluido
  EXCEPT
  SELECT * FROM registro_ocupacao_01_nao_excluido
  WHERE ocupacao_covid_cli % 1 != 0
    OR ocupacao_covid_uti % 1 != 0
    OR ocupacao_hospitalar_cli % 1 != 0
    OR ocupacao_hospitalar_uti % 1 != 0
    OR saida_suspeita_obitos % 1 != 0
    OR saida_suspeita_altas % 1 != 0
    OR saida_confirmada_obitos % 1 != 0
    OR saida_confirmada_altas % 1 != 0
    OR ocupacao_suspeito_cli % 1 != 0
    OR ocupacao_confirmado_cli % 1 != 0
    OR ocupacao_suspeito_uti % 1 != 0
    OR ocupacao_confirmado_uti % 1 != 0;
```

### 0.3.4 Validação de colunas de acordo com informações do dicionário de dados

De acordo com o dicionário de dados, estabelecemos alguns critérios para validar os valores das colunas de ocupação e saídas:

- Se *ocupacao\_hospitalar\_cli* for igual a zero ou nulo, então, necessariamente, *ocupacao\_covid\_cli* também deve ser igual a zero ou nulo.

```

SELECT
    COUNT(*)::DECIMAL AS sem_logica_count,
    (SELECT COUNT(*)::DECIMAL
     FROM registro_ocupacao_02_sem_decimais) AS total_count,
    ROUND(COUNT(*)::DECIMAL / (SELECT COUNT(*)::DECIMAL
                               FROM registro_ocupacao_02_sem_decimais)
          , 4) AS sem_logica_percentual
FROM registro_ocupacao_02_sem_decimais
WHERE (ocupacao_hospitalar_cli = 0
      AND ocupacao_covid_cli > 0)
OR (ocupacao_hospitalar_cli IS NULL
    AND ocupacao_covid_cli IS NOT NULL);

```

- Se *ocupacao\_hospitalar\_uti* for igual a zero ou nulo, então, necessariamente, *ocupacao\_covid\_uti* também deve ser igual a zero ou nulo.

```

-- Validacao coluna ocupacao_covid_uti
SELECT
    COUNT(*)::DECIMAL AS sem_logica_count,
    (SELECT COUNT(*)::DECIMAL
     FROM registro_ocupacao_02_sem_decimais) AS total_count,
    ROUND(COUNT(*)::DECIMAL / (SELECT COUNT(*)::DECIMAL
                               FROM registro_ocupacao_02_sem_decimais)
          , 4) AS sem_logica_percentual
FROM registro_ocupacao_02_sem_decimais
WHERE (ocupacao_hospitalar_uti = 0
      AND ocupacao_covid_uti > 0)
OR (ocupacao_hospitalar_uti IS NULL
    AND ocupacao_covid_uti IS NOT NULL);

```

- – Se *ocupacao\_covid\_cli* for igual a zero ou nulo, então, necessariamente, *ocupacao\_suspeito\_cli* e *ocupacao\_confirmado\_cli* também devem ser iguais a zero ou nulos.

```

-- Validacao colunas ocupacao_suspeito_cli e ocupacao_confirmado_cli
SELECT
    COUNT(*)::DECIMAL AS sem_logica_count,
    (SELECT COUNT(*)::DECIMAL
     FROM registro_ocupacao_02_sem_decimais) AS total_count,
    ROUND(COUNT(*)::DECIMAL / (SELECT COUNT(*)::DECIMAL
                               FROM registro_ocupacao_02_sem_decimais)
          , 4) AS sem_logica_percentual

```

```

FROM registro_ocupacao_02_sem_decimais
WHERE (ocupacao_covid_cli = 0
      AND (ocupacao_suspeito_cli > 0
          OR ocupacao_confirmado_cli > 0))
OR (ocupacao_covid_cli IS NULL
    AND (ocupacao_suspeito_cli IS NOT NULL
        OR ocupacao_confirmado_cli IS NOT NULL));

```

- – Se *ocupacao\_covid\_cli* for igual a zero ou nulo, então, necessariamente, *ocupacao\_suspeito\_cli* e *ocupacao\_confirmado\_cli* também devem ser iguais a zero ou nulos.

```

-- Validacao colunas ocupacao_suspeito_utl e ocupacao_confirmado_utl
SELECT
COUNT(*)::DECIMAL AS sem_logica_count,
(SELECT COUNT(*)::DECIMAL
 FROM registro_ocupacao_02_sem_decimais) AS total_count,
ROUND(COUNT(*)::DECIMAL / (SELECT COUNT(*)::DECIMAL
                           FROM registro_ocupacao_02_sem_decimais)
      , 4) AS sem_logica_percentual
FROM registro_ocupacao_02_sem_decimais
WHERE (ocupacao_covid_utl = 0
      AND (ocupacao_suspeito_utl > 0
          OR ocupacao_confirmado_utl > 0))
OR (ocupacao_covid_utl IS NULL
    AND (ocupacao_suspeito_utl IS NOT NULL
        OR ocupacao_confirmado_utl IS NOT NULL));

```

Com base nessas validações, percebemos que cerca de 62% dos registros das colunas *ocupacao\_suspeito\_utl*, *ocupacao\_confirmado\_utl*, *ocupacao\_suspeito\_cli* e *ocupacao\_confirmado\_cli* apresentam inconsistências e, por isso, decidimos não utilizá-las nas análises.

Ademais, como menos de 1% dos registros das colunas *ocupacao\_covid\_cli* e *ocupacao\_covid\_utl* apresentam inconsistências, criaremos uma visualização que filtre os valores consistentes dessas colunas, conforme o **script abaixo**.

```

-- 03: valida regras de acordo com interpretacao do dicionario de dados
CREATE OR REPLACE VIEW registro_ocupacao_03_dados_limpos AS
SELECT
    _id, data_notificacao, criado_em, atualizado_em,
    id_hospital, id_local, id_status,

```

```

        ocupacao_covid_cli, ocupacao_covid_uti,
        ocupacao_hospitalar_cli, ocupacao_hospitalar_uti,
        saida_suspeita_obitos, saida_suspeita_altas,
        saida_confirmada_obitos, saida_confirmada_altas
FROM registro_ocupacao_02_sem_decimais
EXCEPT
SELECT
    _id, data_notificacao, criado_em, atualizado_em,
    id_hospital, id_local, id_status,
    ocupacao_covid_cli, ocupacao_covid_uti,
    ocupacao_hospitalar_cli, ocupacao_hospitalar_uti,
    saida_suspeita_obitos, saida_suspeita_altas,
    saida_confirmada_obitos, saida_confirmada_altas
FROM registro_ocupacao_02_sem_decimais
WHERE (ocupacao_hospitalar_cli = 0
        AND ocupacao_covid_cli > 0)
    OR (ocupacao_hospitalar_cli IS NULL
        AND ocupacao_covid_cli IS NOT NULL)
    OR (ocupacao_hospitalar_uti = 0
        AND ocupacao_covid_uti > 0)
    OR (ocupacao_hospitalar_uti IS NULL
        AND ocupacao_covid_uti IS NOT NULL);

```

### 0.3.5 Remoção de notificações duplicadas

Alguns registros continham notificações duplicadas, ou seja, com a mesma data de notificação e o mesmo hospital. Para resolver isso, criamos uma view que remove as duplicatas, mantendo apenas a notificação mais recente (com base na data de atualização e criação).

```

-- 04: Remove notificacoes duplicadas, trazendo aquelas com data de atualizacao mais recente
CREATE OR REPLACE VIEW registro_ocupacao_04_sem_duplicatas AS
WITH ranked AS (
    SELECT *,
        ROW_NUMBER() OVER (
            PARTITION BY data_notificacao, id_hospital
            ORDER BY atualizado_em DESC, criado_em DESC, _id DESC
        ) AS rn
    FROM registro_ocupacao_03_dados_limpos
)
SELECT
    _id, id_hospital, data_notificacao, id_local, id_status,

```

```

ocupacao_covid_cli, ocupacao_covid_uti,
ocupacao_hospitalar_cli, ocupacao_hospitalar_uti,
saida_suspeita_obitos, saida_suspeita_altas,
saida_confirmada_obitos, saida_confirmada_altas
FROM ranked
WHERE rn = 1;

```

### 0.3.6 Criação de colunas calculadas

Para facilitar a análise, criamos colunas calculadas que agregam informações relevantes. As colunas criadas foram: *ocupacao\_covid*, *ocupacao\_hospitalar*, *saida\_covid\_obitos*, *saida\_covid\_altas*, *saida\_covid*, *entrada\_covid\_calculada*.

```

-- 05: Cria colunas calculadas saida_obitos, saida_altas, saida_covid, saida_covid_calculada
CREATE OR REPLACE VIEW registro_ocupacao_05_colunas_calculadas_filtradas AS
WITH com_colunas_calculadas AS(
    SELECT
        _id, id_hospital, data_notificacao, id_local, id_status,

        (ocupacao_covid_cli + ocupacao_covid_uti) AS ocupacao_covid,

        (ocupacao_hospitalar_cli +
        ocupacao_hospitalar_uti) AS ocupacao_hospitalar,

        (COALESCE(saida_suspeita_obitos, 0) +
        COALESCE(saida_confirmada_obitos, 0)) AS saida_covid_obitos,

        (COALESCE(saida_suspeita_altas, 0) +
        COALESCE(saida_confirmada_altas, 0)) AS saida_covid_altas,

        (COALESCE(saida_suspeita_obitos, 0) +
        COALESCE(saida_confirmada_obitos, 0) +
        COALESCE(saida_suspeita_altas, 0) +
        COALESCE(saida_confirmada_altas, 0)) AS saida_covid

    FROM registro_ocupacao_04_sem_duplicatas),

com_colunas_calculadas2 AS(
    SELECT *,

        ( ocupacao_covid -

```



```

        COALESCE((LAG(ocupacao_covid) OVER(
            ORDER BY id_hospital, data_notificacao)), 0) +
        saida_covid ) AS entrada_covid_calculada

FROM com_colunas_calculadas)

SELECT
    _id, id_hospital,
    data_notificacao, id_local, id_status,
    ocupacao_covid, ocupacao_hospitalar,
    saida_covid_obitos, saida_covid_altas,
    CASE WHEN entrada_covid_calculada < 0
        THEN saida_covid + (-1) * entrada_covid_calculada
        ELSE saida_covid
    END AS saida_covid_calculada,
    CASE
        WHEN entrada_covid_calculada < 0 THEN 0
        ELSE entrada_covid_calculada
    END AS entrada_covid_calculada
FROM com_colunas_calculadas2;

```

### 0.3.7 Criação de série temporal

Para facilitar a análise temporal dos dados, criamos uma série temporal que combina todas as datas de notificação com os hospitais, locais e status. Isso nos permite analisar a evolução dos dados ao longo do tempo, mesmo quando alguns registros estão ausentes.

```

-- 06: Cria série temporal
CREATE OR REPLACE VIEW registro_ocupacao_06_serie_temporal AS
WITH calendario AS(

    SELECT GENERATE_SERIES(
        MIN(data_notificacao),
        MAX(data_notificacao),
        '1 day') AS data_notificacao

    FROM registro_ocupacao_05_colunas_calculadas_filtradas),

combinacoes_hospital_local_status AS(
    SELECT DISTINCT id_hospital, id_local, id_status
    FROM registro_ocupacao_05_colunas_calculadas_filtradas

```

```

),

serie_temporal AS (
    SELECT
        cal.data_notificacao AS data_notificacao,
        hls.id_hospital,
        hls.id_local,
        hls.id_status
    FROM calendario cal
    CROSS JOIN combinacoes_hospital_local_status hls
    ORDER BY 2, 3, 4, 1
)

SELECT
    st.data_notificacao AS data_notificacao,
    st.id_hospital,
    st.id_local,
    st.id_status,
    ro.ocupacao_covid,
    ro.ocupacao_hospitalar,
    ro.saida_covid_obitos,
    ro.saida_covid_altas,
    ro.saida_covid_calculada,
    ro.entrada_covid_calculada
FROM serie_temporal st
LEFT JOIN registro_ocupacao_05_colunas_calculadas_filtradas ro
    ON st.id_hospital = ro.id_hospital
    AND st.id_local = ro.id_local
    AND st.id_status = ro.id_status
    AND DATE(st.data_notificacao) = DATE(ro.data_notificacao)
ORDER BY st.id_hospital, st.id_local, st.id_status, st.data_notificacao;

```

### 0.3.8 Execução de ‘Last Observation Carried Forward (LOCF)’ para tratamento de valores nulos em séries temporais.

Para lidar com valores nulos na série temporal, aplicamos a técnica de “Last Observation Carried Forward (LOCF)”, que preenche os valores nulos com o último valor observado (data imediatamente mais recente). Isso é especialmente útil em séries temporais, onde a continuidade dos dados é importante para a análise.

```

-- 07: Executa 'Last Observation Carried Forward (LOCF)' para tratamento de valores nulos e
CREATE OR REPLACE VIEW registro_ocupacao_07_LOCF AS
SELECT
    data_notificacao,
    id_hospital,
    id_local,
    id_status,
    CASE
        WHEN ocupacao_covid IS NULL
        THEN LAG(ocupacao_covid) OVER (
            PARTITION BY id_hospital, id_local, id_status
            ORDER BY data_notificacao)
        ELSE ocupacao_covid
    END AS ocupacao_covid,

    CASE
        WHEN ocupacao_hospitalar IS NULL
        THEN LAG(ocupacao_hospitalar) OVER (
            PARTITION BY id_hospital, id_local, id_status
            ORDER BY data_notificacao)
        ELSE ocupacao_hospitalar
    END AS ocupacao_hospitalar,

    COALESCE(saida_covid_obitos, 0) AS saida_covid_obitos,
    COALESCE(saida_covid_altas, 0) AS saida_covid_altas,
    COALESCE(saida_covid_calculada, 0) AS saida_covid_calculada,
    COALESCE(entrada_covid_calculada, 0) AS entrada_covid_calculada
FROM registro_ocupacao_06_serie_temporal;

```

### 0.3.9 Criação de materialized view como tabela final para facilitar uso durante consulta dos dados tratados.

Criamos uma **materialized view** final que contém todos os dados tratados e prontos para análise. Escolhemos esse objeto porque ele permite consultas mais rápidas e eficientes, especialmente em grandes volumes de dados. Essa tabela final é ordenada por hospital, data de notificação, local e status, facilitando a consulta e análise dos dados.

```

-- 08: Cria tabela final com dados prontos para analise
CREATE MATERIALIZED VIEW registro_ocupacao_final AS
SELECT * FROM registro_ocupacao_07_LOCF
ORDER BY id_hospital, data_notificacao, id_local, id_status;

```

## 0.4 Análise de Dados

Com um tema tão amplo, a análise de dados foi dividida em três partes principais: detecção de anomalias, análise de texto e evolução das altas e dos óbitos ao longo do tempo. Nossa curiosidade em explorar mais dados sobre um período tão catastrófico da história da humanidade nos levou, também, a realizar análises adicionais.

### 0.4.1 Views e/ou CTE's

Foram utilizadas **views** e **CTEs** para organizar as consultas SQL e facilitar a análise dos dados. Essas estruturas foram empregadas tanto nos **scripts** de limpeza de dados quanto nas análises que seguem abaixo.

### 0.4.2 Subconsultas

Foram utilizadas subconsultas para a limpeza dos dados.

### 0.4.3 Detecção de Anomalias: registros com picos isolados

```
-- 3.1 Detecção de Anomalias temporais
CREATE OR MATERIALIZED VIEW anomalias_temporais_1 AS
WITH estat AS (
    SELECT
        id_hospital,
        avg(ocupacao_covid) AS med_c,
        avg(ocupacao_hospitalar) AS med_h,
        STDDEV_POP(ocupacao_covid) AS sd_c,
        STDDEV_POP(ocupacao_hospitalar) AS sd_h
    FROM registro_ocupacao_final
    GROUP BY id_hospital
)

SELECT * FROM estat;
```

```
-- Usando partition by

CREATE OR MATERIALIZED VIEW anomalias_temporais_2 AS
WITH estat AS (
    SELECT
```

```

        id_hospital,
        data_notificacao,
        ocupacao_covid,
        ocupacao_hospitalar,
        AVG(ocupacao_covid) OVER (PARTITION BY id_hospital) AS med_c,
        AVG(ocupacao_hospitalar) OVER (PARTITION BY id_hospital) AS med_h,
        STDDEV_POP(ocupacao_covid) OVER (PARTITION BY id_hospital) AS sd_c,
        STDDEV_POP(ocupacao_hospitalar) OVER (PARTITION BY id_hospital) AS sd_h
    FROM registro_ocupacao_final
)

SELECT
    id_hospital,
    data_notificacao,
    ocupacao_covid,
    ocupacao_hospitalar,
    med_c,
    med_h,
    sd_c,
    sd_h
FROM estat
WHERE ocupacao_covid > 3*sd_c OR ocupacao_hospitalar > 3*sd_h;

```

#### 0.4.4 Detecção de Anomalias: registros com picos isolados

```

-- 3.2 Detecção de Anomalias Temporais

CREATE OR MATERIALIZED VIEW anomalias_temporais_3 AS
WITH obitos_por_data AS(
    SELECT
        DATE_TRUNC('day', data_notificacao) AS data_notificacao,
        SUM(saida_covid_obitos) AS obitos
    FROM registro_ocupacao_final
    GROUP BY 1
    ORDER BY 1
),
base AS (
    SELECT
        data_notificacao,
        obitos,

```

```

-- Média móvel dos últimos 30 dias
AVG(obitos) OVER (
  ORDER BY data_notificacao
  ROWS BETWEEN 29 PRECEDING AND CURRENT ROW
) AS media_movel_obitos,

-- Desvio padrão móvel dos últimos 30 dias
STDDEV_POP(obitos) OVER (
  ORDER BY data_notificacao
  ROWS BETWEEN 29 PRECEDING AND CURRENT ROW
) AS desvio_movel_obitos

FROM obitos_por_data
),

anomalias AS(
  SELECT
    data_notificacao,
    obitos,
    media_movel_obitos,
    desvio_movel_obitos,

    -- Limites dinâmicos
    media_movel_obitos + 3 * desvio_movel_obitos AS limite_superior,
    media_movel_obitos - 3 * desvio_movel_obitos AS limite_inferior,

    -- Z-score
    (obitos - media_movel_obitos) / NULLIF(desvio_movel_obitos, 0) AS z_score,

    -- Verificação de anomalias (picos (1), normalidades (0) ou quedas (-1))
    CASE
      WHEN obitos > media_movel_obitos + 3 * desvio_movel_obitos THEN 1
      WHEN obitos < media_movel_obitos - 3 * desvio_movel_obitos THEN -1
      ELSE 0
    END AS anomalia

  FROM base
  ORDER BY data_notificacao
)
SELECT
  data_notificacao,
  obitos,

```

```

ROUND(media_movel_obitos, 2) AS media_movel_obitos,
ROUND(desvio_movel_obitos, 2) AS desvio_movel_obitos,
ROUND(limite_inferior, 2) AS limite_inferior,
ROUND(limite_superior, 2) AS limite_superior,
ROUND(z_score, 2) AS z_score,
anomalia
FROM anomalias
-- WHERE anomalia = 1 OR anomalia = -1
ORDER BY data_notificacao;

```

#### 0.4.5 Análise de Texto: origem dos dados

```

CREATE OR MATERIALIZED VIEW analise_textual_origem_dos_dados AS
WITH n_reg AS (
    SELECT
        id_status,
        COUNT(id_status) AS qtde
    FROM registro_ocupacao
    GROUP BY id_status
),
jun AS (
    SELECT
        n_reg.id_status,
        n_reg.qtde,
        status_envio.origem
    FROM n_reg
    JOIN status_envio
        ON n_reg.id_status = status_envio.id_status
),
agrupado AS (
    SELECT
        origem,
        SUM(qtde) AS qtde
    FROM jun
    GROUP BY origem
    ORDER BY qtde DESC
)
SELECT * FROM agrupado;

```

#### 0.4.6 Evolução das altas e óbitos ao longo do tempo

```
-- 5 Evolucao das altas vs. obitos
CREATE OR MATERIALIZED VIEW evolucao_obitos_altas AS
WITH truncado AS (
    SELECT
        DATE(DATE_TRUNC('day', data_notificacao)) AS dia,
        DATE(DATE_TRUNC('month', data_notificacao)) AS mes,
        DATE(DATE_TRUNC('quarter', data_notificacao)) AS trimestre,
        DATE(DATE_TRUNC('year', data_notificacao)) AS ano,
        saida_covid_obitos AS obitos,
        saida_covid_altas AS altas
    FROM registro_ocupacao_final
),
axo_dia AS (
    SELECT
        dia,
        SUM(obitos) AS obitos,
        SUM(altas) AS altas
    FROM truncado
    GROUP BY dia
    ORDER BY dia DESC
),
axo_mes AS (
    SELECT
        mes,
        SUM(obitos) AS obitos,
        SUM(altas) AS altas
    FROM truncado
    GROUP BY mes
    ORDER BY mes DESC
),
axo_trimestre AS (
    SELECT
        trimestre,
        SUM(obitos) AS obitos,
        SUM(altas) AS altas
    FROM truncado
    GROUP BY trimestre
    ORDER BY trimestre DESC
),
axo_ano AS (
```



```

SELECT
    ano,
    SUM(obitos) AS obitos,
    SUM(altas) AS altas
FROM truncado
GROUP BY ano
ORDER BY ano DESC
)

SELECT * FROM axo_trimestre;

```

#### 0.4.7 Evolução da ocupados COVID vs ocupados hospitalar

Com esta consulta, podemos verificar diariamente quanto a ocupação de leitos por Covid-19 representa do total de leitos ocupados.

```

-- 6 Evolução da razão entre leitos ocupados por pacientes com COVID e o total de leitos ocupados
CREATE OR MATERIALIZED VIEW evolucao_ocupacao_covid_vs_hospitalar AS
WITH p_ocup AS (
    SELECT
        data_notificacao,
        id_hospital,
        CASE
            WHEN ocupacao_hospitalar > 0 THEN (ocupacao_covid / ocupacao_hospitalar)
            ELSE NULL
        END AS p_ocup_covid
    FROM registro_ocupacao_final
)
SELECT * FROM p_ocup
ORDER BY id_hospital, data_notificacao;

```

#### 0.4.8 Ocupação máxima de leitos por hospital

```

-- 7 Máximo de ocupações por hospital
CREATE OR MATERIALIZED VIEW max_ocupacao_hospital AS
WITH ocup_max AS (
    SELECT
        id_hospital,
        MAX(ocupacao_covid) AS ocup_c,

```

```
MAX(ocupacao_hospitalar) AS ocup_h,  
MAX(saida_covid_obitos) AS saida_c_obitos,  
MAX(saida_covid_altas) AS saida_c_altas  
FROM registro_ocupacao_final  
GROUP BY id_hospital  
)  
  
SELECT * FROM ocup_max  
WHERE ocup_c IS NOT NULL AND ocup_h IS NOT NULL  
ORDER BY ocup_h DESC, id_hospital;
```

## 0.5 Observações Finais

Dados são apenas dados até que se tenha um profissional por trás dos bastidores trabalhando:

- Comunicando-se curiosamente com aqueles que mais entendem sobre o negócio ao qual os dados registram os fatos;
- Entendendo o problema com o qual se está lidando, mesmo que nem sempre tudo esteja claro no começo;
- Utilizando tecnicamente ferramentas para tratar, modelar e analisar os dados;
- Interpretando os resultados de forma crítica e contextualizada;
- Compartilhando o conhecimento adquirido de forma clara e objetiva.

Aprender SQL durante o semestre e aplicá-lo praticamente durante este trabalho final foi uma experiência enriquecedora. A linguagem SQL se mostrou uma ferramenta poderosa e completa para trabalhar com dados (ganhando ainda mais o meu apreço), permitindo lidar com grandes volumes de dados. Além disso, este trabalho revelou a importância da organização e estruturação dos dados para facilitar análises futuras.